Condição underflow e overflow. Para diferenciar estas duas condições vamos utilizar o seguinte SPF (2,3,-1,2). Neste caso, vamos representar os números $x_1 = 0.38$, $x_2 = 5.3$ e $x_3 = 0.15$ dados na base 10. Lembrando que:

De uma maneira geral, um número x é representado na base β por:

$$x = \pm \left[\frac{d_1}{\beta} + \frac{d_2}{\beta^2} + \frac{d_3}{\beta^3} + \dots + \frac{d_t}{\beta^t} \right] \cdot \beta^{\exp}$$

$$0 \le d_i \le (\beta - 1); i = 2, 3, \dots, n.$$

$$\exp_{\min} \le \exp \le \exp_{\max}$$

$$\left[\frac{d_1}{\beta} + \frac{d_2}{\beta^2} + \frac{d_3}{\beta^3} + \dots + \frac{d_t}{\beta^t}\right] \rightarrow \text{ \'e chamada de mantissa e \'e a parte do número que representa seus dígitos significativos e t \'e o número de dígitos significativos do sistema de representação, comumente chamado de precisão de máquina.$$

Solução: Fazendo os cálculos, obtemos:

$$(0.38)_{10} = 0.110 \times 2^{-1}$$

 $(5.3)_{10} = 0.101 \times 2^{3}$
 $(0.15)_{10} = 0.100 \times 2^{-2}$

Assim no SPF (2,3,-1,2) apenas o primeiro número pode ser representado no sistema, pois para o segundo temos **OVERFLOW**, e para o terceiro **UNDERFLOW**.

Exemplo 2) Dado o número 12.20 que está na base 4, representá-lo na base 3.

Solução:

$$(12)_{4} = 1 \times 4^{1} + 2 \times 4^{0} = (6)_{10}$$

$$(0.20)_{4} = 2 \times 4^{-1} + 0 \times 4^{-2} = (0.5)_{10}$$

$$Logo,$$

$$(12.20)_{4} = (6.5)_{10}$$

$$6 \mid 3 \qquad 0.5 \times 3 = 1.5$$

$$0.5 \times 3 = 1.5$$

$$\vdots$$

Assim: $(6.5)_{10} = (20.11...)$. Logo $(12.20)_4 = (20.11...)_3$. Neste caso é importante ressaltar que o número na base 4 tem representação exata na base 10, mas não na base 3.

A representação de um número depende fundamentalmente da máquina utilizada pois seu Sistema estabelecerá a base numérica adotada, o comprimento de palavra, etc.

Se um dado número X não tem representação finita na base numérica deste Sistema, ou se o comprimento da palavra da máquina não comporta X, uma aproximação será obtida.

Regra geral para se arrendondar um número:

Dado x , seja x' sua representação SPF (β ,t,m,M) adotando arredondamento. Se x=0, então x'=0. Se x≠0 , então escolhemos s e e tais que:

$$|x| = s \times \beta^e$$
, onde $\beta^{-1} \left(1 - \frac{1}{2} \beta^{-t} \right) \le s < 1 - \frac{1}{2} \beta^{-t}$ (1)

Se $\underline{\mathbf{e}}$ está fora do intervalo [m,M] não temos condições de representar o número no sistema. Se $\underline{\mathbf{e}}$ ε [m,M] então calculamos:

$$s + \frac{1}{2}\beta^{-t} = 0.d_1 d_2 ... d_{t+1} ...$$

e truncamos em t dígitos. Assim, o número arredondado será:

$$x' = (\sin a x) (0.d_1 d_2 ... d_t) \beta^e$$

Considere o sistema SPF (10,3,-5,5). Representar neste sistema os números

 $X_1 = 1234.56$

 $X_2 = -0.00054962$

 $X_3 = 0.9995$

 $x_4 = 123456.7 e$

 $X_5 = -0.0000001$

Solução: Primeiramente deve-se avaliar os valores permitidos para s. Desde que β =10 e t=3, usando (1), tem-se que:

$$10^{-1} \left(1 - \frac{1}{2} 10^{-3} \right) \le s < 1 - \frac{1}{2} 10^{-3}$$

Fazendo os cálculos, obtém-se:

 $0.09995 \le s < 0.9995$

Agora podemos representar os números no sistema dado:

a) Para $x_1 = 1234.56$, obtém-se:

$$|x_1| = 1234.56 = 0.123456 \times 10^4$$

 $s + (1/2)x10^{-3} = 0.123456 + 0.0005 = 0.123956$
 $x_1' = 0.123x10^4$

- b) Para $x_2 = -0.00054962$, obtém-se: $|x| = 0.54962 \times 10^{-3}$ $s + (1/2)x10^{-3} = 0.54962 + 0.0005 = 0.55012$ $x_2' = -0.550 \times 10^{-3}$
- c) Para $x_3 = 0.9995$, observe que neste caso não podemos representar $|x_3| = 0.9995 \times 10^0$, pois neste caso s não pertence ao seu intervalo, e o número arredondado não estaria escrito na forma dos elementos do sistema. Assim, neste caso, considera-se:

$$| x_3 | = 0.09995 \times 10^1$$

 $s + (1/2) \times 10^{-3} = 0.09995 + 0.0005 = 0.10045$
 $x_3' = 0.100 \times 10^1$

d) Para $x_4 = 123456.7$, obtém-se:

$$| x_4 | = 0.1234567 \times 10^6$$

e) Para
$$x_5 = -0.0000001$$
, obtém-se:
| $x_5 | = 0.1 \times 10^{-6}$

Observe que tanto em **d)** quanto em **e)** não podemos representar o número no sistema dado, pois em d) temos overflow e em e) temos, underflow.

Assim, em linhas gerais, para arredondar um número de base 10, devemos apenas observar o primeiro dígito a ser descartado.

Se este dígito é menor que 5 deixamos os dígitos inalterados; se é maior ou igual a 5 devemos somar 1 ao último dígito remanescente.

OPERAÇÕES EM PONTO FLUTUANTE

Considere uma máquina qualquer e uma série de operações aritméticas. Pelo fato do arredondamento ser feito após cada operação, temos, ao contrário do que é válido para números reais, que as operações aritméticas (adição, subtração, divisão e multiplicação) não são nem associativas e nem distributivas.

Vamos procurar ilustrar este fato através de exemplos.

Ex. 1) Efetuar as operações indicadas:

a)
$$(11.4 + 3.18) + 5.05 e 11.4 + (3.18 + 5.05)$$

b)
$$\frac{3.18 \times 11.4}{5.05}$$
 e $\left(\frac{3.18}{5.05}\right) \times 11.4$

c)
$$3.18 \times (5.05 + 11.4)$$
 e $3.18 \times 5.05 + 3.18 \times 11.4$

Para cada item, fazendo o arredondamento após cada uma das operações efetuadas, segue que:

a)
$$(11.4 + 3.18) + 5.05 = 14.6 + 5.05 = 19.7$$

enquanto

$$11.4 + (3.18 + 5.05) = 11.4 + 8.23 = 19.6$$

$$b) \quad \frac{3.18 \times 11.4}{5.05} = \frac{36.3}{5.05} = 7.19$$

enquanto

$$\left(\frac{3.18}{5.05}\right) \times 11.4 = 0.630 \times 11.4 = 7.18$$

c)
$$3.18 \times (5.05 + 11.4) = 3.18 \times 16.5 = 52.3$$

enquanto

$$3.18 \times 5.05 + 3.18 \times 11.4 = 16.1 + 36.3 = 52.4$$

Exemplo) Avaliar o polinômio:

$$P(x) = x^3 - 6x^2 + 4x - 0.1$$

No ponto P(5.24) e comparar com o resultado exato.

Solução: para calcular o valor exato consideremos todos os dígitos de uma máquina, sem usar arredondamento em cada operação. Assim:

$$P(5.24) = 143.8777824 - 164.7456 + 20.96 - 0.1 = -0.00776$$
 (valor exato)

Agora usando arrendondamento em cada operação efetuada, obtemos:

$$P(5.24) = 5.24 \times 27.5 - 6 \times 27.5 + 4 \times 5.24 - 0.1$$

= 144. - 165. + 21.0 - 0.1
= - 0.1 (somando da esquerda para a direita)
= 0.00 (somando da direita para a esquerda)

Entretanto, observe que P(x) pode ser escrito como:

$$P(x) = x(x(x-6)+4) - 0.1$$

Assim

$$P(5.24) = 5.24 (5.24 (5.24 - 6) + 4) - 0.1$$

 $P(5.24) = 5.24 (-3.98 + 4) - 0.1$
 $P(5.24) = 5.24 (0.02) - 0.1$
 $P(5.24) = 0.105 - 0.1$
 $P(5.24) = 0.005 (sinal errado)$

Observando os exemplos, verifica-se que erros consideráveis podem ocorrer durante a execução de um algoritmo. Isto se deve ao fato que existe limitação da máquina e também porque os erros de arredondamento são introduzidso a cada operação efetuada. Em consequência, pode-se obter resultados diferentes mesmo que sejam utilizados métodos matemáticos equivalentes.

Assim devemos ser capazes de desenvolver um algoritmo tal que os efeitos da aritmética discreta do computador permaneçam inofensivos quando um grande número de operações sejam executadas.

São erros provenientes da utilização de processos que deveriam ser infinitos ou muito grandes para determinação de um valor e que por razões práticas são truncados.

Estes processos infinitos são muito utilizados na avaliação de funções matemáticas, tais como, exponenciação, funções trigonométricas e várias outras.

Considere a seguinte série:

$$seno(x) = x - \frac{x^3}{3!} + \frac{x^5}{5!} - \frac{x^7}{7!} \cdots$$

Uma máquina pode calcular a função seno(x) através do seguinte trecho de programa:

```
FACT = 1
SENO = X
SINAL = 1
DO 10 I = 3,N,2
FACT = FACT*I*(I-1)
SINAL = - SINAL
TERMO = SINAL*(X**I) / FACT
SENO = SENO + TERMO
```

10 CONTINUE

Para que o valor ao final do trecho de programa se tenha na variável SENO o valor de sen (x), o valor de N no comando DO deve ser bem grande, o que tornaria o cálculo ineficiente.

A solução adotada é de interromper os cálculos quando uma determinada precisão é atingida.

De uma maneira geral, pode-se dizer que o erro de truncamento pode ser diminuído até chegar a ficar da ordem do erro de arredondamento, a partir deste ponto não faz sentido diminuir-se mais, pois o erro de arredondamento será dominante.

Seguinte este raciocíonio o programa deve ser alterado para:

```
I = 3
FACT = 1
SENO = X
SINAL = 1

5 CONTINUE
FACT = FACT*I*(I-1)
SINAL = - SINAL
TERMO = SINAL*(X**I) / FACT
SENO = SENO + TERMO
I = I +2
IF (TERMO.GT.PRECISAO) GO TO 5
```

Onde,

PRECISAO é o valor de precisão da mantissa

Exercícios) Calcular os erros de arredondamento e truncamento das operações a seguir. Considere a base decimal 10 e 4 dígitos de mantissa.

- a) $t = 0.937 \times 10^4 \text{ e y} = 0.1272 \times 10^2 \text{ . Obter } (t+y);$
- b) Considerando t e y do ítem a), obtenha (ty).